

Projekt: Analiza ličnosti i njenih mračnih crta

Lana Barišić

Marta Leš

Lucija Lovrić

Karla Šoštar

2026-01-21

Motivacija i opis problema

Ličnost je jedno od temeljnih područja psihologije i najčešće se opisuje petofaktorskim Big Five modelom koji uključuje ekstraverziju, ugodnost, savjesnost, neuroticizam i otvorenost. Uz osnovne crte ličnosti, često se ispituju i mračne crte, odnosno mračna trijada koju čine narcizam, psihopatija i makijavelizam. Cilj ovog projekta je ispitati povezanost osnovnih i mračnih crta ličnosti, te ostalih obilježja poput spola i dobi, sa sklonošću stresu, depresiji i anksioznosti.

Učitavanje i pregled podataka

Podatke iz CSV datoteke učitavamo u varijablu *dataset* kako bismo ih mogle bolje analizirati.

```
dataset <- read_csv('Personality_data.csv')
```

```
## New names:
## Rows: 578 Columns: 18
## -- Column specification
## ----- Delimiter: "," chr
## (5): age, sex, ethnicity simplified, student status, employment status dbl
## (13): ...1, depression, anxiety, stress, narcissism, machiavelism, psych...
## i Use 'spec()' to retrieve the full column specification for this data. i
## Specify the column types or set 'show_col_types = FALSE' to quiet this message.
## * ' -> '...1'
```

Dalje, prikazemo prvih nekoliko redaka da vidimo primjere vrijednosti svakog od stupaca.

```
head(dataset)
```

```
## # A tibble: 6 x 18
##   ...1 depression anxiety stress narcissism machiavelism psychoticism sadism
##   <dbl>      <dbl>   <dbl>   <dbl>      <dbl>      <dbl>      <dbl>   <dbl>
## 1      1      1.24    1.08    0.505      1.50      0.254     -0.201  0.0193
## 2      2      1.07    1.16    0.266      0.791      0.562      1.31    0.870
## 3      3     -0.581  -0.263  -0.556     -0.267     -0.692     -0.691  -0.208
## 4      4      3.03    1.99    1.94      0.415      0.856      2.19    1.10
## 5      5      1.22   -0.774   0.104     -2.34     -1.99     -0.733  -1.57
## 6      6      0.828  -0.186   0.728     -0.333      1.59      1.87    1.72
## # i 10 more variables: neuroticism <dbl>, extraversion <dbl>, openness <dbl>,
```

```
## # agreeableness <dbl>, conscientiousness <dbl>, age <chr>, sex <chr>,
## # 'ethnicity simplified' <chr>, 'student status' <chr>,
## # 'employment status' <chr>
```

Zatim, pomoću metoda `names()` i `glimpse()`, dajemo si bolji uvid u tipove podataka i strukturu.

```
names(dataset)
```

```
## [1] "...1"           "depression"       "anxiety"
## [4] "stress"          "narcissism"       "machiavelism"
## [7] "psychoticism"    "sadism"           "neuroticism"
## [10] "extraversion"    "openness"         "agreeableness"
## [13] "conscientiousness" "age"              "sex"
## [16] "ethnicity simplified" "student status"   "employment status"
```

```
glimpse(dataset)
```

```
## Rows: 578
## Columns: 18
## $ ...1          <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, ~
## $ depression    <dbl> 1.24028239, 1.07356352, -0.58072240, 3.03206310~
## $ anxiety       <dbl> 1.07785482, 1.15519418, -0.26310737, 1.98720356~
## $ stress        <dbl> 0.50512161, 0.26619388, -0.55579868, 1.94173788~
## $ narcissism    <dbl> 1.50455897, 0.79126351, -0.26693805, 0.41549063~
## $ machiavelism  <dbl> 0.25408691, 0.56182597, -0.69164422, 0.85587890~
## $ psychoticism  <dbl> -0.20141634, 1.31253355, -0.69076562, 2.1866752~
## $ sadism        <dbl> 0.01933759, 0.86951395, -0.20777818, 1.10452165~
## $ neuroticism   <dbl> -0.20124424, 0.56874269, -0.19237042, 1.4630829~
## $ extraversion  <dbl> 0.64878308, 0.44347482, -1.75862486, -1.8731478~
## $ openness      <dbl> 0.2455288, -0.9359119, -0.6614584, 1.8180786, --
## $ agreeableness <dbl> -0.02353314, -1.17591066, -0.31643069, 0.655438~
## $ conscientiousness <dbl> -0.042944525, -1.043162336, -0.481776915, 0.039~
## $ age          <chr> "CONSENT_REVOKED", "CONSENT_REVOKED", "29", "37~
## $ sex          <chr> "CONSENT_REVOKED", "CONSENT_REVOKED", "Female",~
## $ 'ethnicity simplified' <chr> "CONSENT_REVOKED", "CONSENT_REVOKED", "Black", ~
## $ 'student status' <chr> "CONSENT_REVOKED", "CONSENT_REVOKED", "DATA_EXP~
## $ 'employment status' <chr> "CONSENT_REVOKED", "CONSENT_REVOKED", "DATA_EXP~
```

Prema uvidu u strukturu podataka vidljivo je da je varijabla **age** tipa *character*, što nije prikladno jer bi u statističkim modelima bila tretirana kao kategorijska umjesto numerička varijabla. Stoga je varijabla **age** pretvorena u numerički tip podataka.

Varijabla **sex** predstavlja kategorijsku varijablu te je, radi ispravne primjene u regresijskim modelima, pretvorena u tip *factor*.

Kako bi se osigurala valjanost analize, iz uzorka su uklonjeni svi ispitanici koji sadrže vrijednosti *CONSENT_REVOKED* ili *DATA_EXPIRED*, budući da ti zapisi ne predstavljaju stvarne podatke ispitanika.

```
data_clean <- dataset %>%
  filter(
    if_all(everything(),
      ~ !(. %in% c("CONSENT_REVOKED", "DATA_EXPIRED")))
  ) %>%
```

```
mutate(
  age = as.numeric(age),
  sex = factor(sex)
)

head(data_clean)

## # A tibble: 6 x 18
##   ...1 depression anxiety stress narcissism machiavelism psychoticism sadism
##   <dbl>         <dbl>   <dbl>   <dbl>         <dbl>         <dbl>         <dbl>   <dbl>
## 1      4      3.03     1.99   1.94         0.415         0.856         2.19   1.10
## 2      5      1.22    -0.774  0.104        -2.34        -1.99        -0.733 -1.57
## 3      6      0.828    -0.186  0.728        -0.333        1.59         1.87   1.72
## 4      7      0.0276   0.182  0.498         0.807         1.65         0.568  0.0681
## 5      9      0.633     1.14   0.421        -0.309        0.634         0.219  0.0423
## 6     10     -0.267    -1.68   0.188         0.608         0.294         0.442  0.780
## # i 10 more variables: neuroticism <dbl>, extraversion <dbl>, openness <dbl>,
## #   agreeableness <dbl>, conscientiousness <dbl>, age <dbl>, sex <fct>,
## #   'ethnicity simplified' <chr>, 'student status' <chr>,
## #   'employment status' <chr>
```

Jesu li ljudi s izraženijom mračnom trijadom skloniji depresiji?

Po analizi podataka već odrađenoj u uvodu znamo da radimo s numeričkim podacima, te da je za ispitivanje povezanosti osobina mračne trijade i depresije prikladno raditi linearnu regresiju. Prema tome, nezavisne varijable ovdje su: narcizam, makijavelizam i psihotizam, a zavisna varijabla je depresija.

```
describe(data_clean %>%
  select(depression, narcissism, machiavelism, psychoticism))
```

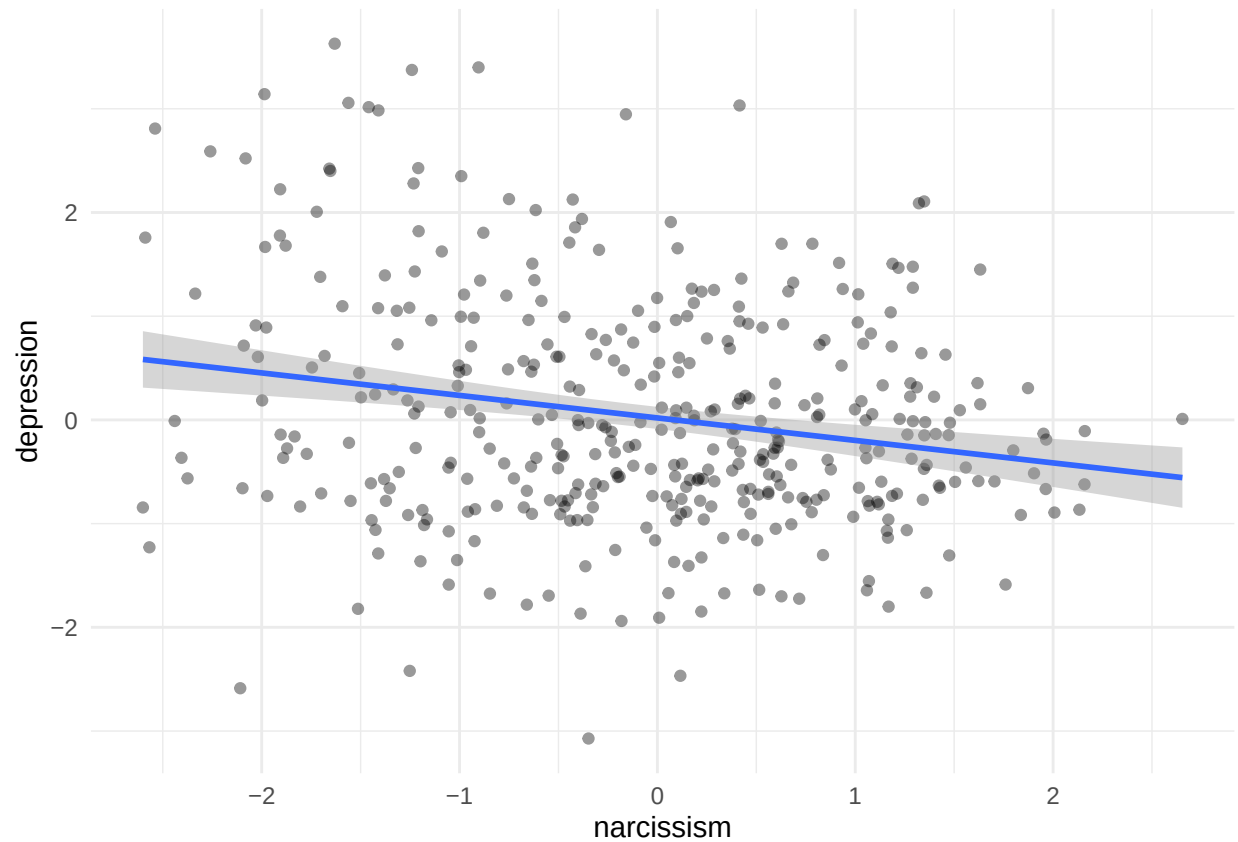
```
##           vars    n mean  sd median trimmed  mad   min  max range  skew
## depression     1 398  0.04 1.10  -0.14  -0.04  0.96 -3.07  3.63  6.70  0.63
## narcissism     2 398 -0.08 1.07   0.02  -0.05  1.16 -2.60  2.65  5.25 -0.16
## machiavelism   3 398 -0.05 1.08   0.05   0.00  1.09 -2.91  2.39  5.30 -0.37
## psychoticism   4 398 -0.08 1.00  -0.20  -0.14  1.04 -2.00  2.99  4.99  0.48
##           kurtosis    se
## depression      0.48 0.06
## narcissism     -0.63 0.05
## machiavelism    -0.41 0.05
## psychoticism    -0.48 0.05
```

Vrijednosti svake od varijable kreću se negdje unutar intervala od -3.0 i 3.0, s medijanima i srednjim vrijednostima uvijek blizu nule. Također, uz $n=398$, znamo da radimo s velikim uzorkom što povećava statističku snagu analize.

Za potrebe analize zasebnog utjecaja svake od ovih varijabli, procijeniti ćemo jednostavne **modele linearne regresije**, pri čemu će se za svaku nezavisnu varijablu izgraditi poseban model.

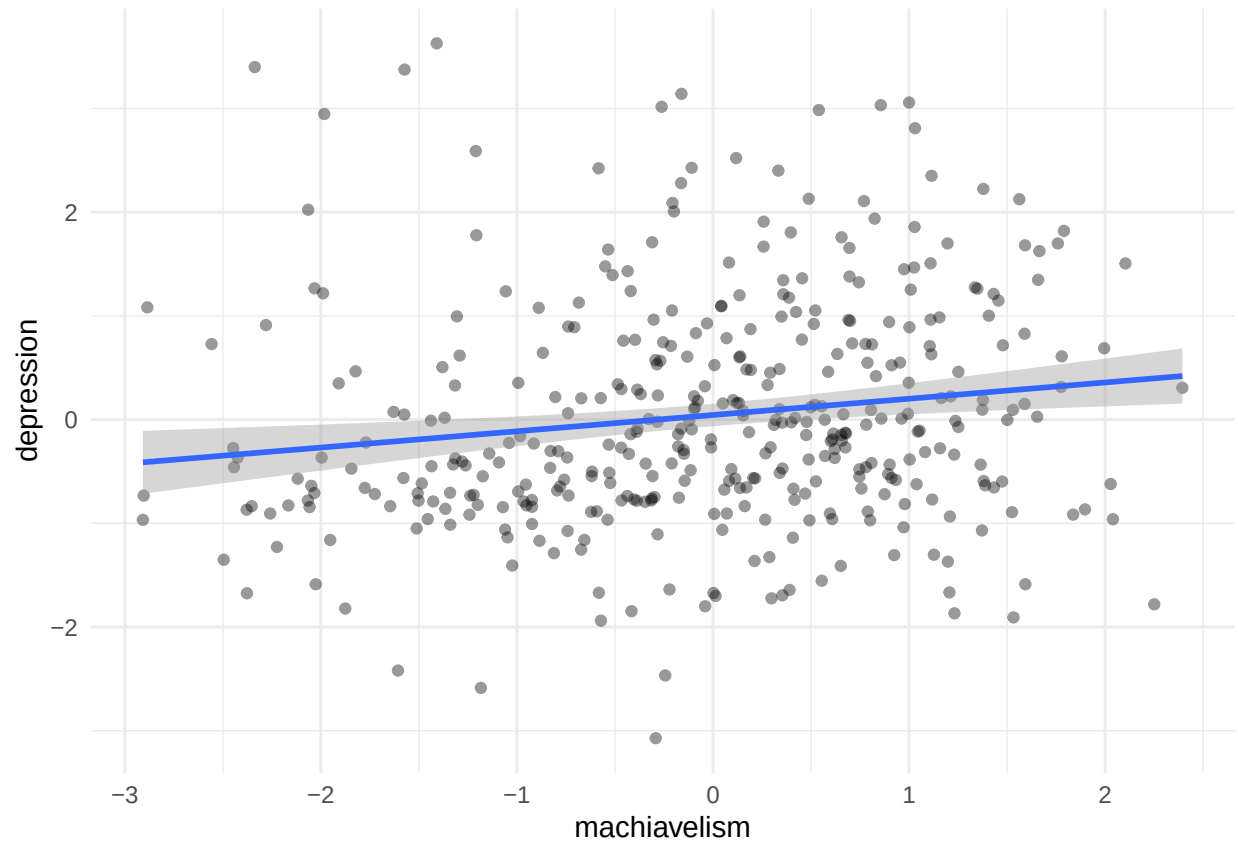
```
ggplot(data_clean, aes(narcissism, depression)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = TRUE) +
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```



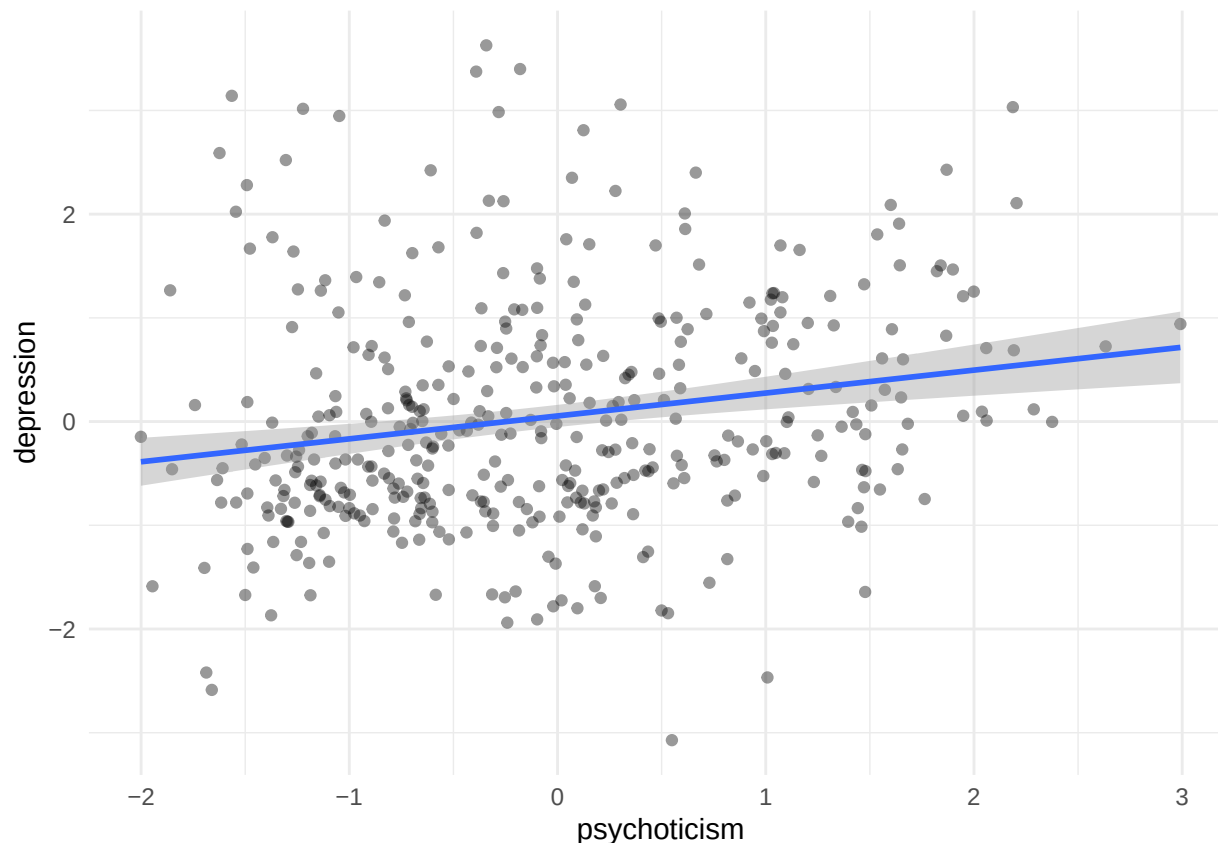
```
ggplot(data_clean, aes(machiavelism, depression)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = TRUE) +
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```



```
ggplot(data_clean, aes(psychoticism, depression)) +  
  geom_point(alpha = 0.4) +  
  geom_smooth(method = "lm", se = TRUE) +  
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```



Nagibi pravaca služe kao potvrda utjecaja pojedine nezavisne varijable na varijablu depresija. Model narcizma jedini ima negativan nagib, ukazujući na negativan utjecaj, dok psihoticizam i makijavelizam imaju pozitivan učinak.

Iduće, pretpostavljene zaključke dobivene analizom grafova linearne regresije potvrditi ćemo izračunom Pearsonovih korelacijskih koeficijenata.

```
cor.test(data_clean$depression, data_clean$narcissism)
```

```
##
## Pearson's product-moment correlation
##
## data: data_clean$depression and data_clean$narcissism
## t = -4.2976, df = 396, p-value = 2.176e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.3031034 -0.1151869
## sample estimates:
## cor
## -0.2110948
```

```
cor.test(data_clean$depression, data_clean$machiavelism)
```

```
##
## Pearson's product-moment correlation
```

```
##
## data: data_clean$depression and data_clean$machiavelism
## t = 3.1025, df = 396, p-value = 0.002057
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.05660396 0.24857887
## sample estimates:
## cor
## 0.1540449
```

```
cor.test(data_clean$depression, data_clean$psychoticism)
```


```
##
## Pearson's product-moment correlation
##
## data: data_clean$depression and data_clean$psychoticism
## t = 4.0662, df = 396, p-value = 5.767e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.1039454 0.2927352
## sample estimates:
## cor
## 0.2001979
```

Pearsonovom korelacijskom analizom utvrđena je statistički značajna negativna povezanost između narcizma i depresije ($r = -0.21$, $p < 0.001$). Makijavelizam ($r = 0.15$, $p = 0.002$) i psihoticizam ($r = 0.20$, $p < 0.001$) pokazali su statistički značajnu pozitivnu povezanost s depresijom. Veličine učinaka su male do umjerene.

Ovo se može prikazati i matrično:

```
vars1 <- data_clean %>%
  select(depression, narcissism, machiavelism, psychoticism) %>%
  na.omit()

corrplot(cor(vars1))
```



Među prediktorima su prisutne umjerene pozitivne korelacije, no nijedna ne upućuje na problematičnu multikolinearnost. Ovo ćemo još formalno analizirati koristeći, ponovno, Pearsonove korelacije.

```
#Zakomentiramo ispis ovih testova da bi izbjegle redundantnost ispisa
#cor.test(data_clean$machiavelism, data_clean$narcissism)
#cor.test(data_clean$machiavelism, data_clean$psychoticism)

cor.test(data_clean$narcissism, data_clean$machiavelism)
```

```
##
## Pearson's product-moment correlation
##
## data: data_clean$narcissism and data_clean$machiavelism
## t = 8.961, df = 396, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.3254326 0.4891514
## sample estimates:
## cor
## 0.4105959
```

```
#cor.test(data_clean$narcissism, data_clean$psychoticism)

cor.test(data_clean$psychoticism, data_clean$narcissism)
```

```
##
```



```
## Pearson's product-moment correlation
##
## data: data_clean$psychoticism and data_clean$narcissism
## t = 7.8298, df = 396, p-value = 4.519e-14
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.2778423 0.4483037
## sample estimates:
## cor
## 0.3661405
```

```
cor.test(data_clean$psychoticism, data_clean$machiavelism)
```

```
##
## Pearson's product-moment correlation
##
## data: data_clean$psychoticism and data_clean$machiavelism
## t = 9.3422, df = 396, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.3409053 0.5022790
## sample estimates:
## cor
## 0.4249627
```

Pearsonove korelacije između nezavisnih varijabli pokazale su umjerene pozitivne povezanosti između makijavelizma, narcizma i psihotičizma (r u rasponu 0,36–0,42, $p < 0,001$). Iako su ove osobine povezane, snaga korelacija ne sugerira problematičnu multikolinearnost, što podupire uključivanje njih kao zasebnih prediktora u regresijski model.

Sada možemo definirati model **višestruke linearne regresije**, gdje gledamo sveukupni utjecaj mračne trijade na depresiju.

```
model_dark_triad <- lm(depression ~ narcissism + machiavelism + psychoticism,
                        data = data_clean)

summary(model_dark_triad)
```

```
##
## Call:
## lm(formula = depression ~ narcissism + machiavelism + psychoticism,
##     data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.3437 -0.6086 -0.1376  0.5302  3.5540
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   0.03894    0.05100   0.763 0.445638
## narcissism   -0.39957    0.05334  -7.490 4.55e-13 ***
## machiavelism  0.20893    0.05434   3.845 0.000141 ***
## psychoticism  0.28178    0.05770   4.884 1.52e-06 ***
```


```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.013 on 394 degrees of freedom
## Multiple R-squared:  0.1648, Adjusted R-squared:  0.1585
## F-statistic: 25.92 on 3 and 394 DF,  p-value: 2.545e-15
```

Rezultati reiteriraju prijašnje zaključke da je narcisizam negativno značajan prediktor depresije ($\beta = -0.40$, $p < 0.001$), dok su makijavelizam ($\beta = 0.21$, $p < 0.001$) i psihoticizam ($\beta = 0.28$, $p < 0.001$) pozitivno značajni prediktori. Model je statistički značajan (F-statistic = 25.92, $p < 0.001$). Međutim, ukupna prediktivna snaga modela je umjerena (R-squared oko 0.16), što sugerira da postoje i drugi faktori koji utječu na depresiju.

Kako bismo provjerili postoje li drugi, prikladniji i značajniji, prediktori prikazat ćemo korelacijsku matricu sa ostalim varijablama.

```
vars2 <- data_clean %>%
  select(depression, narcissism, machiavelism, psychoticism,
         neuroticism, extraversion, openness,
         agreeableness, conscientiousness,
         age) %>%
  na.omit()

corrplot(cor(vars2))
```



Tu su vidljive pozitivne povezanosti depresije s neuroticizmom, psihoticizmom i najmanje makijavelizmom. S druge strane, negativnu korelaciju s depresijom imaju narcizam, ekstraverzija i savjesnost, nešto manje

kod ugodnosti. Najjače povezanosti su sa ekstraverzijom i neuroticizmom, koji su međusobno negativno korelirani.

```
model_2 <- lm(depression ~ narcissism + extraversion + neuroticism + conscientiousness + agreeableness +
              data = data_clean)
```

```
summary(model_2)
```

```
##
## Call:
## lm(formula = depression ~ narcissism + extraversion + neuroticism +
##     conscientiousness + agreeableness + psychoticism, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.0698 -0.4943  0.0391  0.4561  2.9942
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.017541   0.042738   0.410  0.68172
## narcissism     -0.007888   0.053502  -0.147  0.88287
## extraversion   -0.238504   0.060134  -3.966 8.68e-05 ***
## neuroticism     0.456224   0.055935   8.156 4.76e-15 ***
## conscientiousness -0.030049   0.055976  -0.537  0.59170
## agreeableness    0.038033   0.052069   0.730  0.46556
## psychoticism    0.169456   0.054041   3.136  0.00184 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8458 on 391 degrees of freedom
## Multiple R-squared:  0.4222, Adjusted R-squared:  0.4133
## F-statistic: 47.61 on 6 and 391 DF, p-value: < 2.2e-16
```

Model značajno predviđa depresiju ($R^2 = 0.42$, $p < 0.001$). Neuroticizam je bio najsnažniji pozitivni prediktor depresije ($\beta = 0.46$, $p < 0.001$), dok je ekstraverzija imala značajan negativan učinak ($\beta = -0.24$, $p < 0.001$). Psihoticizam je također pokazao umjeren, ali značajan pozitivan doprinos ($\beta = 0.17$, $p = 0.001$). Narcizam, savjesnost i ugodnost nisu bili statistički značajni prediktori ($p > 0.05$), što upućuje na to da njihov odnos s depresijom nije jedinstven nakon kontrole ostalih osobina.

Još ćemo provjeriti predstavlja li kolinearnost značajki problem za ovu interpretaciju:

```
vif <- function(model) {
  X <- model.matrix(model)[, -1]
  vif_values <- sapply(1:ncol(X), function(i) {
    lm_fit <- lm(X[, i] ~ X[, -i])
    1 / (1 - summary(lm_fit)$r.squared)
  })
  names(vif_values) <- colnames(X)
  return(vif_values)
}

vif(model_2)
```

```
##          narcissism          extraversion          neuroticism conscientiousness
```


```
##          1.834314          2.376552          1.930409          1.706299
##    agreeableness    psychoticism
##          1.598789          1.623147
```

VIF faktori za sve prediktore manji su od 5, što ukazuje da ne postoji značajna multikolinearnost među varijablama.

Još je preostalo provjeriti **pretpostavke regresija**, tj. prate li reziduali ovih modela normalnu distribuciju.


```
qqnorm(
  residuals(model_dark_triad),
  main = "QQ-plot reziduala modela depresije i mračne trijade"
)
qqline(residuals(model_dark_triad))
```

QQ-plot reziduala modela depresije i mračne trijade




```
hist(residuals(model_dark_triad), breaks = 20, main = "Histogram reziduala modela depresije i mračne tr
```

Histogram reziduala modela depresije i mracne trijade




```
qqnorm(  
  residuals(model_2),  
  main = "QQ-plot reziduala modela depresije i ostalih značajki"  
)  
qqline(residuals(model_2))
```

QQ-plot reziduala modela depresije i ostalih znacajki



```
hist(residuals(model_2), breaks = 20, main = "Histogram reziduala modela depresije i ostalih znacajki")
```

Histogram reziduala modela depresije i ostalih znacajki



Normalnost reziduala provjerena je pomoću QQ-plota i histograma, koji su pokazali približno normalnu distribuciju, uz manja odstupanja na krajevima distribucije. Odstupanja su zastupljenija kod drugog modela koji ne uključuje samo varijable mračne trijade, već i ostale značajke.

Zaključak

Pokazali smo da osobine koje čine mračnu trijadu: psihoticizam, makijavelizam i narcizam, same po sebi utječu na depresiju, ali njihov učinak nije jednako snažan kao učinak nekih drugih osobina, poput niske ekstraverzije i visokog neuroticizma s elementima psihoticizma.

Postoje li razlike u nekim crtama ličnosti među spolovima?


```
table(data_clean$sex)
```

```
##  
##           Female           Male Prefer not to say  
##           186           209             3
```

```
df_sex <- data_clean %>%  
  filter(sex %in% c("Male", "Female"))
```

```
big_five <- df_sex %>%
  pivot_longer(
    cols = c(neuroticism, extraversion, openness, agreeableness, conscientiousness),
    names_to = "trait",
    values_to = "score"
  )

ggplot(big_five, aes(x = sex, y = score, fill = sex)) +
  geom_boxplot() +
  facet_wrap(~ trait, scales = "free") +
  theme_minimal() +
  labs(
    title = "Big Five osobine po spolu (Male vs Female)",
    x = "Spol",
    y = "Rezultat"
  )
```




Vizualna analiza boxplotova ukazuje na obrasce razlika između spolova koji su u skladu s teorijskim očekivanjima. Najizraženije razlike uočavaju se kod neuroticizma i ugodnosti, pri čemu žene u prosjeku postižu više vrijednosti, što je vidljivo kroz više medijane i pomak distribucije prema višim vrijednostima.

Kod ekstraverzije, otvorenosti i savjesnosti razlike između spolova su manje izražene; medijani su vrlo slični, a distribucije se u velikoj mjeri preklapaju, što upućuje na izostanak izraženih spolnih razlika u tim osobinama na razini deskriptivne analize.

Prije provedbe t-testa za nezavisne uzorke, potrebno je provjeriti jesu li zadovoljene osnovne pretpostavke testa, uključujući normalnost distribucije, homogenost varijanci te nezavisnost uzoraka.

Za početak ćemo provjeriti pretpostavku o normalnosti uzorka.

```
ggplot(df_sex, aes(sample = neuroticism)) +  
  stat_qq() + stat_qq_line() +  
  facet_wrap(~sex)
```



```
# ggplot(df_sex, aes(sample = agreeableness)) +  
#   stat_qq() + stat_qq_line() +  
#   facet_wrap(~sex)  
#  
# ggplot(df_sex, aes(sample = openness)) +  
#   stat_qq() + stat_qq_line() +  
#   facet_wrap(~sex)  
#  
# ggplot(df_sex, aes(sample = extraversion)) +  
#   stat_qq() + stat_qq_line() +  
#   facet_wrap(~sex)  
#  
# ggplot(df_sex, aes(sample = conscientiousness)) +  
#   stat_qq() + stat_qq_line() +  
#   facet_wrap(~sex)
```

Distribucije su provjerene za sve osobine među spolovima i za sve osobine vrijedu da priližno slijede normalnu distribuciju. Zatim ćemo provjeriti varijance.

```

traits <- c("neuroticism", "agreeableness", "openness", "extraversion", "conscientiousness")

var_by_sex <- df_sex %>%
  group_by(sex) %>%
  summarise(across(all_of(traits), ~ var(.x, na.rm = TRUE)))

```

```
var_by_sex
```

```

## # A tibble: 2 x 6
##   sex      neuroticism agreeableness openness extraversion conscientiousness
##   <fct>         <dbl>         <dbl>    <dbl>         <dbl>         <dbl>
## 1 Female         1.11           0.977     1.13           1.23           0.897
## 2 Male           1.06           1.07     1.08           1.14           1.03

```

```

var_tests <- lapply(traits, function(tr) {
  f <- as.formula(paste(tr, "~ sex"))
  vt <- var.test(f, data = df_sex)
  tibble(
    trait = tr,
    F_statistic = round(vt$statistic, 3),
    p_value = round(vt$p.value, 4)
  )
})

```

```
bind_rows(var_tests)
```

```

## # A tibble: 5 x 3
##   trait          F_statistic p_value
##   <chr>          <dbl>    <dbl>
## 1 neuroticism      1.05    0.740
## 2 agreeableness    0.916    0.543
## 3 openness         1.05    0.752
## 4 extraversion     1.08    0.606
## 5 conscientiousness 0.875    0.354

```

Rezultati testa za jednakost varijanci pokazuju da ni za jednu od analiziranih osobina ličnosti nije utvrđena statistički značajna razlika u varijancama između muškaraca i žena. Sve dobivene p-vrijednosti veće su od 0.05, stoga se u svim slučajevima ne odbacuje nul-hipoteza o jednakosti varijanci.

Dodatno, promatramo dvije nezavisne skupine: Female i Male (ostale ćemo ukloniti).

Stoga, sve pretpostavke su zadovoljene i provest ćemo t-test za nezavisne uzorke.

```

# t-test za svaku osobinu
results <- lapply(traits, function(tr) {
  formula <- as.formula(paste(tr, "~ sex")) #npr. neuroticism ~ sex
  test <- t.test(formula, data = df_sex)
  print(test$estimate)
  tibble(
    trait = tr, #naziv osobine
    t_statistic = round(test$statistic, 3), #t vrijednost
    p_value = round(test$p.value, 5),
    mean_female = round(test$estimate["mean in group Female"], 3),

```

```

    mean_male = round(test$estimate["mean in group Male"], 3)
  )
})

```

```

## mean in group Female    mean in group Male
##           0.18251516      -0.08261147
## mean in group Female    mean in group Male
##           0.2738572      -0.1091680
## mean in group Female    mean in group Male
##           0.10694830      -0.02212707
## mean in group Female    mean in group Male
##          -0.14239955       0.04568951
## mean in group Female    mean in group Male
##           0.07941870       0.03722745

```

```

results_df <- bind_rows(results)
results_df

```

```

## # A tibble: 5 x 5
##   trait          t_statistic p_value mean_female mean_male
##   <chr>          <dbl>    <dbl>      <dbl>     <dbl>
## 1 neuroticism      2.52  0.0120        0.183     -0.083
## 2 agreeableness    3.76  0.00019        0.274     -0.109
## 3 openness         1.22  0.223         0.107     -0.022
## 4 extraversion    -1.71  0.0873        -0.142      0.046
## 5 conscientiousness 0.428 0.669         0.079      0.037

```

Rezultati dvostranih t-testova za nezavisne uzorke ukazuju na postojanje statistički značajnih spolnih razlika u pojedinim dimenzijama ličnosti. Žene postižu značajno više prosječne rezultate od muškaraca u neuroticizmu ($t = 2.52$, $p = 0.012$) i ugodnosti ($t = 3.76$, $p < 0.001$).

Za otvorenost ($t = 1.22$, $p = 0.223$), ekstraverziju ($t = -1.71$, $p = 0.087$) i savjesnost ($t = 0.43$, $p = 0.669$) nisu utvrđene statistički značajne razlike između spolova, iako su uočene blage razlike u prosječnim vrijednostima.

Sad ćemo pogledati mračne osobine.


```

dark_traits <- df_sex %>%
  pivot_longer(
    cols = c(narcissism, machiavelism, psychoticism, sadism),
    names_to = "trait",
    values_to = "score"
  )

ggplot(dark_traits, aes(x = sex, y = score, fill = sex)) +
  geom_boxplot() +
  facet_wrap(~ trait, scales = "free") +
  theme_minimal() +
  labs(
    title = "Mračne osobine ličnosti po spolu (Male vs Female)",
    x = "Spol",
    y = "Rezultat"
  )

```


Mracne osobine licnosti po spolu (Male vs Female)



Vizualna analiza mračnih osobina ličnosti ukazuje na izraženije spolne razlike u odnosu na Big Five osobine. Muškarci u prosjeku postižu više rezultate u makijavelizmu, narcizmu, psihoticizmu i sadizmu, što je vidljivo kroz više medijane i pomak distribucija prema višim vrijednostima. Razlike su posebno izražene kod sadizma i psihoticizma, dok su kod makijavelizma i narcizma prisutne umjerene razlike uz djelomično preklapanje distribucija.

Također, za mračne osobine ličnosti provest ćemo provjeru pretpostavki normalnosti distribucije i jednakosti varijanci. Analiza se temelji na istim dvjema nezavisnim skupinama ispitanika (Female i Male).

```
ggplot(df_sex, aes(sample = narcissism)) +  
  stat_qq() + stat_qq_line() +  
  facet_wrap(~sex)
```



```
#
# ggplot(df_sex, aes(sample = machiavelism)) +
#   stat_qq() + stat_qq_line() +
#   facet_wrap(~sex)
#
# ggplot(df_sex, aes(sample = psychoticism)) +
#   stat_qq() + stat_qq_line() +
#   facet_wrap(~sex)
#
# ggplot(df_sex, aes(sample = sadism)) +
#   stat_qq() + stat_qq_line() +
#   facet_wrap(~sex)
```

Distribucije u skupinama su priližno normalne. Test je proveden za sve mračne osobine.

```
dark <- c("narcissism", "machiavelism", "psychoticism", "sadism")
```

```
var_by_sex <- df_sex %>%
  group_by(sex) %>%
  summarise(across(all_of(dark), ~ var(.x, na.rm = TRUE)))
```

```
var_by_sex
```

```
## # A tibble: 2 x 5
##   sex      narcissism machiavelism psychoticism sadism
```

```
##    <fct>          <dbl>          <dbl>          <dbl> <dbl>
## 1 Female          1.12            1.24            0.981 0.870
## 2 Male            1.17            1.05            0.967 1.08
```

```
var_tests <- lapply(dark, function(tr) {
  f <- as.formula(paste(tr, "~ sex"))
  vt <- var.test(f, data = df_sex)
  tibble(
    trait = tr,
    F_statistic = round(vt$statistic, 3),
    p_value = round(vt$p.value, 4)
  )
})

bind_rows(var_tests)
```

```
## # A tibble: 4 x 3
##   trait      F_statistic p_value
##   <chr>          <dbl>   <dbl>
## 1 narcissism      0.957   0.764
## 2 machiavelism    1.18    0.243
## 3 psychoticism    1.01    0.916
## 4 sadism          0.802   0.125
```

Varijance mračnih osobina ličnosti između muškaraca i žena su usporedive i približno jednake, stoga je pretpostavka homogenosti varijanci zadovoljena.

Provest ćemo t-test.

```
dark <- c("narcissism", "machiavelism", "psychoticism", "sadism")

dark_results <- lapply(dark, function(tr) {
  formula <- as.formula(paste(tr, "~ sex"))
  test <- t.test(formula, data = df_sex)
  tibble(
    trait = tr,
    t_statistic = round(test$statistic, 3),
    p_value = round(test$p.value, 5),
    mean_female = round(test$estimate["mean in group Female"], 3),
    mean_male = round(test$estimate["mean in group Male"], 3)
  )
})

dark_results_df <- bind_rows(dark_results)
dark_results_df
```

```
## # A tibble: 4 x 5
##   trait      t_statistic p_value mean_female mean_male
##   <chr>          <dbl>   <dbl>          <dbl>   <dbl>
## 1 narcissism     -2.58 0.0102         -0.221   0.057
## 2 machiavelism   -3.75 0.0002         -0.27    0.136
## 3 psychoticism   -3.22 0.00138        -0.251   0.069
## 4 sadism         -6.80 0              -0.385   0.29
```

U analizi mračnih osobina ličnosti pronađene su jasne spolne razlike. Budući da je u t-testu korišten format $t \sim \text{sex}$, negativne t-vrijednosti ukazuju na više rezultate u skupini muškaraca u odnosu na žene.

Rezultati pokazuju da muškarci postižu statistički značajno više rezultate na svim analiziranim mračnim crtama — narcizmu, makijavelizmu, psihoticizmu i sadizmu (sve $p < 0.05$). Najizraženija razlika uočena je kod sadizma, gdje muškarci ostvaruju znatno više prosječne vrijednosti u odnosu na žene, što upućuje na izraženije spolne razlike u ovoj dimenziji ličnosti.

Jačaju li neke osobine s godinama?

Nezavisna varijabla (prediktori):

→ Dob (age)

Zavisne varijable:

→ Ekstraverzija (extraversion) → Ugodnost (agreeableness) → Savjesnost (conscientiousness) → Neuroticizam (neuroticism) → Otvorenost (openness)

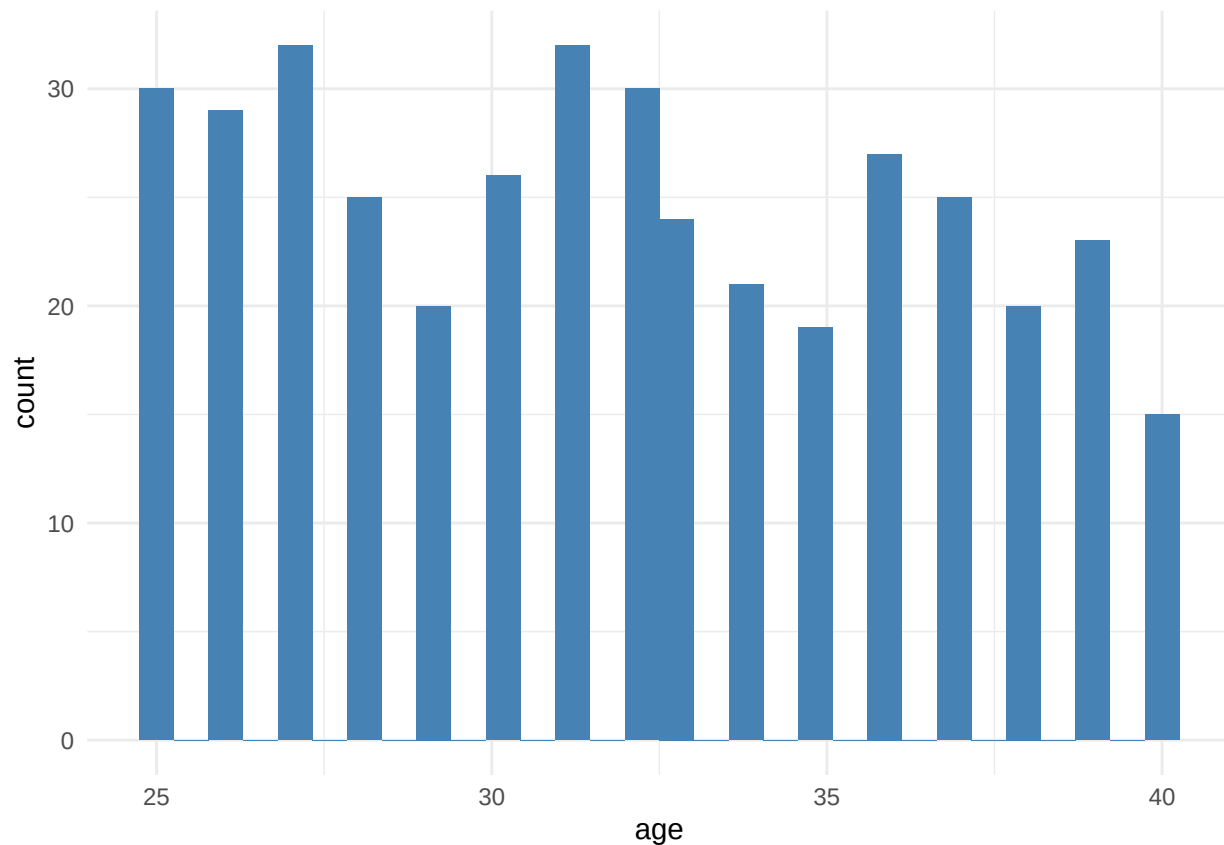
U nastavku se analiza provodi zasebno za svaku osobinu. Budući da su i dob i crte ličnosti kontinuirane varijable, a istraživačko pitanje se odnosi na linearnu promjenu s godinama, jednostavna linearna regresija predstavlja najprikladniji statistički pristup.

```
describe(data_clean %>%
  select(age, extraversion, agreeableness,
    conscientiousness, neuroticism, openness))
```

```
##           vars    n mean   sd median trimmed  mad   min   max range
## age           1 398 31.92 4.54  32.00   31.83 5.93 25.00 40.00 15.00
## extraversion   2 398 -0.04 1.09   0.09    0.02 1.05 -3.31  2.54  5.85
## agreeableness  3 398  0.07 1.03   0.10    0.07 1.12 -3.12  2.77  5.89
## conscientiousness 4 398  0.05 0.99   0.07    0.08 1.05 -2.94  2.40  5.34
## neuroticism    5 398  0.05 1.05  -0.07    0.00 1.05 -2.27  2.95  5.22
## openness       6 398  0.04 1.05  -0.09    0.04 0.95 -3.38  2.99  6.36
##           skew kurtosis    se
## age           0.12    -1.18 0.23
## extraversion  -0.50    -0.11 0.05
## agreeableness -0.06    -0.33 0.05
## conscientiousness -0.26    -0.28 0.05
## neuroticism    0.41    -0.05 0.05
## openness      -0.03     0.33 0.05
```

Deskriptivna statistika pruža osnovni uvid u raspodjelu dobi i razinu pojedinih crta ličnosti u uzorku ispitanika.


```
ggplot(data_clean, aes(age)) +
  geom_histogram(bins = 30, fill = "steelblue") +
  theme_minimal()
```



Histogram dobi prikazuje raspodjelu ispitanika po dobnim skupinama te omogućuje procjenu raspona i strukture dobi u uzorku. Grafički prikaz prikazan je samo za jednu dimenziju ličnosti jer su za ostale dimenzije dobiveni vrlo slični obrasci odnosa s dobi. Radi preglednosti dodatni grafovi nisu uključeni.

```
ggplot(data_clean, aes(age, extraversion)) +  
  geom_point(alpha = 0.4) +  
  geom_smooth(method = "lm", se = TRUE) +  
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

```
#ggplot(data_clean, aes(age, agreeableness)) +
# geom_point(alpha = 0.4) +
# geom_smooth(method = "lm", se = TRUE) +
# theme_minimal()

#ggplot(data_clean, aes(age, conscientiousness)) +
# geom_point(alpha = 0.4) +
# geom_smooth(method = "lm", se = TRUE) +
# theme_minimal()

#ggplot(data_clean, aes(age, neuroticism)) +
# geom_point(alpha = 0.4) +
# geom_smooth(method = "lm", se = TRUE) +
# theme_minimal()

#ggplot(data_clean, aes(age, openness)) +
# geom_point(alpha = 0.4) +
# geom_smooth(method = "lm", se = TRUE) +
# theme_minimal()
```

Raspršeni dijagrami s pripadajućim regresijskim linijama korišteni su za vizualnu procjenu linearnog odnosa između dobi i pojedinih crta ličnosti. Grafički prikazi ne upućuju na izražene linearne trendove, iako se kod nekih osobina može uočiti blagi rast ili pad vrijednosti s porastom dobi.

```
cor.test(data_clean$age, data_clean$extraversion)
```

```
##  
## Pearson's product-moment correlation  
##  
## data: data_clean$age and data_clean$extraversion  
## t = -1.7053, df = 396, p-value = 0.08893  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## -0.18215014 0.01302653  
## sample estimates:  
## cor  
## -0.08538084
```

```
cor.test(data_clean$age, data_clean$agreeableness)
```

```
##  
## Pearson's product-moment correlation  
##  
## data: data_clean$age and data_clean$agreeableness  
## t = 1.2789, df = 396, p-value = 0.2017  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## -0.0343782 0.1614170  
## sample estimates:  
## cor  
## 0.06413658
```

```
cor.test(data_clean$age, data_clean$conscientiousness)
```

```
##  
## Pearson's product-moment correlation  
##  
## data: data_clean$age and data_clean$conscientiousness  
## t = -0.13972, df = 396, p-value = 0.889  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## -0.10524642 0.09134006  
## sample estimates:  
## cor  
## -0.007021018
```

```
cor.test(data_clean$age, data_clean$neuroticism)
```

```
##  
## Pearson's product-moment correlation  
##  
## data: data_clean$age and data_clean$neuroticism  
## t = 0.2454, df = 396, p-value = 0.8063  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:
```

```
## -0.08607148  0.11049500
## sample estimates:
##          cor
## 0.01233089
```


```
cor.test(data_clean$age, data_clean$openness)
```

```
##
## Pearson's product-moment correlation
##
## data:  data_clean$age and data_clean$openness
## t = -0.69464, df = 396, p-value = 0.4877
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.13272862  0.06363051
## sample estimates:
##          cor
## -0.03488574
```

Pearsonove korelacije korištene su kao preliminarna analiza odnosa dobi i crta ličnosti. Rezultati korelacija ne upućuju na statistički značajne povezanosti između dobi i promatranih osobina.

```
vars <- data_clean %>%
  select(age, extraversion, agreeableness,
          conscientiousness, neuroticism, openness) %>%
  na.omit()

corrplot(cor(vars))
```



Korelacijska matrica dodatno potvrđuje izostanak snažnih povezanosti između dobi i pojedinih crta ličnosti.

```
model_consc <- lm(conscientiousness ~ age, data = data_clean)
summary(model_consc)
```

```
##
## Call:
## lm(formula = conscientiousness ~ age, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.99434 -0.68117  0.01346  0.76485  2.34600
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.099902   0.353798   0.282   0.778
## age        -0.001533   0.010973  -0.140   0.889
##
## Residual standard error: 0.9919 on 396 degrees of freedom
## Multiple R-squared:  4.929e-05, Adjusted R-squared:  -0.002476
## F-statistic: 0.01952 on 1 and 396 DF, p-value: 0.889
```

```
model_extra <- lm(extraversion ~ age, data = data_clean)
summary(model_extra)
```

```
##
```

```
## Call:
## lm(formula = extraversion ~ age, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.1645 -0.6666  0.1027  0.7857  2.5834
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.61250    0.38726   1.582  0.1145
## age         -0.02048    0.01201  -1.705  0.0889 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.086 on 396 degrees of freedom
## Multiple R-squared:  0.00729,    Adjusted R-squared:  0.004783
## F-statistic: 2.908 on 1 and 396 DF,  p-value: 0.08893
```

```
model_agree <- lm(agreeableness ~ age, data = data_clean)
summary(model_agree)
```

```
##
## Call:
## lm(formula = agreeableness ~ age, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.1780 -0.7163  0.0236  0.7345  2.6385
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.39279    0.36742  -1.069  0.286
## age          0.01457    0.01140   1.279  0.202
##
## Residual standard error: 1.03 on 396 degrees of freedom
## Multiple R-squared:  0.004114,    Adjusted R-squared:  0.001599
## F-statistic: 1.636 on 1 and 396 DF,  p-value: 0.2017
```

```
model_neuro <- lm(neuroticism ~ age, data = data_clean)
summary(model_neuro)
```

```
##
## Call:
## lm(formula = neuroticism ~ age, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.3342 -0.7428 -0.1191  0.6403  2.9115
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.045980    0.376568  -0.122  0.903
## age          0.002866    0.011679   0.245  0.806
```

```
##
## Residual standard error: 1.056 on 396 degrees of freedom
## Multiple R-squared:  0.0001521, Adjusted R-squared:  -0.002373
## F-statistic: 0.06022 on 1 and 396 DF,  p-value: 0.8063
```

```
model_open <- lm(openness ~ age, data = data_clean)
summary(model_open)
```

```
##
## Call:
## lm(formula = openness ~ age, data = data_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4319 -0.6082 -0.1301  0.6922  2.9697
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.297455   0.373452   0.796   0.426
## age         -0.008046   0.011583  -0.695   0.488
##
## Residual standard error: 1.047 on 396 degrees of freedom
## Multiple R-squared:  0.001217, Adjusted R-squared:  -0.001305
## F-statistic: 0.4825 on 1 and 396 DF,  p-value: 0.4877
```

Za svaku crtu ličnosti provedena je analiza jednostavne linearne regresije u kojoj je dob korištena kao nezavisna varijabla. U niti jednom modelu dob se nije pokazala statistički značajnim prediktorom ($p > 0.05$). Vrijednosti koeficijenta determinacije bile su vrlo niske, što upućuje na slab objašnjavajući doprinos dobi.

Na temelju provedene analize može se zaključiti da se u promatranom uzorku ne uočava statistički značajno jačanje niti slabljenje crta ličnosti s godinama. Dob se u ovom istraživanju nije pokazala značajnim prediktorom promjena u okviru Big Five modela ličnosti.

```
library(broom)

models <- list(
  Extraversion = model_extra,
  Agreeableness = model_agree,
  Conscientiousness = model_consc,
  Neuroticism = model_neuro,
  Openness = model_open
)

results <- lapply(models, tidy) |>
  bind_rows(.id = "Trait") |>
  filter(term == "age")

results
```

```
## # A tibble: 5 x 6
##   Trait      term estimate std.error statistic p.value
##   <chr>    <chr>    <dbl>    <dbl>    <dbl>    <dbl>
## 1 Extraversion age    -0.0205   0.0120    -1.71    0.0889
```

## 2 Agreeableness	age	0.0146	0.0114	1.28	0.202
## 3 Conscientiousness	age	-0.00153	0.0110	-0.140	0.889
## 4 Neuroticism	age	0.00287	0.0117	0.245	0.806
## 5 Openness	age	-0.00805	0.0116	-0.695	0.488

Tablica prikazuje procijenjene regresijske koeficijente za učinak dobi na pojedine crte ličnosti.

Kategorizacija kontinuiranih varijabli provedena je radi primjene hi-kvadrat testa, kojim se ispituje povezanost između dobnih skupina i distribucije razina crta ličnosti.

```
data_clean <- data_clean %>%
  mutate(age_group = case_when(
    age < 30 ~ "Mladi",
    age >= 30 & age < 35 ~ "Srednji",
    age >= 35 ~ "Stariji"
  ))

data_clean$age_group <- factor(data_clean$age_group)
```

Crte ličnosti podijeljene su u tri kategorije (niska, srednja i visoka razina) na temelju terčila distribucije rezultata.

```
traits <- c("extraversion", "agreeableness", "conscientiousness", "neuroticism", "openness")

for (t in traits) {
  data_clean[[paste0(t, "_cat")]] <- cut(
    data_clean[[t]],
    breaks = quantile(data_clean[[t]], probs = c(0, 1/3, 2/3, 1), na.rm = TRUE),
    labels = c("Niska", "Srednja", "Visoka"),
    include.lowest = TRUE
  )
}
```

```
chisq.test(table(data_clean$age_group, data_clean$extraversion_cat))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(data_clean$age_group, data_clean$extraversion_cat)
## X-squared = 2.7214, df = 4, p-value = 0.6055
```

```
chisq.test(table(data_clean$age_group, data_clean$agreeableness_cat))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(data_clean$age_group, data_clean$agreeableness_cat)
## X-squared = 8.7962, df = 4, p-value = 0.0664
```

```
chisq.test(table(data_clean$age_group, data_clean$conscientiousness_cat))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(data_clean$age_group, data_clean$conscientiousness_cat)
## X-squared = 1.176, df = 4, p-value = 0.882
```

```
chisq.test(table(data_clean$age_group, data_clean$neuroticism_cat))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(data_clean$age_group, data_clean$neuroticism_cat)
## X-squared = 5.0875, df = 4, p-value = 0.2784
```

```
chisq.test(table(data_clean$age_group, data_clean$openness_cat))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(data_clean$age_group, data_clean$openness_cat)
## X-squared = 0.79106, df = 4, p-value = 0.9396
```

```
#table(data_clean$age_group, data_clean$openness_cat)
```

Hi-kvadrat testom ispitana je povezanost između dobnih skupina i kategoriziranih razina crta ličnosti. Rezultati nisu pokazali statistički značajnu povezanost između dobi i ekstraverzije, savjesnosti, neuroticizma niti otvorenosti ($p > 0.05$).

Rezultati hi-kvadrat testova nisu pokazali statistički značajnu povezanost između dobnih skupina i osobina.

Kod osobine ugodnosti uočen je povišen hi-kvadrat rezultat (8.80), no pripadajuća p-vrijednost (0.066) ne doseže prag statističke značajnosti. Stoga se ne može zaključiti da se razine ugodnosti značajno razlikuju između dobnih skupina.

Iako je kod ugodnosti uočena blaga tendencija promjene raspodjele razina između dobnih skupina, ona nije statistički potvrđena, što može biti posljedica kategorizacije kontinuiranih varijabli i smanjene statističke snage hi-kvadrat testa.

Na temelju hi-kvadrat analize kategoriziranih varijabli ne može se zaključiti da se crte ličnosti značajno mijenjaju ili jačaju s godinama u promatranom uzorku.

Jesu li crte ličnosti i sklonost stresu, depresiji i anksioznosti povezane sa zanimanjem?

```
df_job <- data_clean %>% mutate(
  occupation_group = if_else(
    `student status` == "Yes",
    "Student",
    `employment status`
  )
) %>% filter(!occupation_group %in% c("Other", "Due to start a new job within the next month", "Not in
table(df_job$occupation_group)
```



```
##
##           Full-Time           Part-Time
##           201             36
##           Student Unemployed (and job seeking)
##           109             24
```


```
df_job %>%
  group_by(occupation_group) %>%
  summarise(
    n = n(),
    mean_stress = mean(stress, na.rm = TRUE),
    mean_depression = mean(depression, na.rm = TRUE),
    mean_anxiety = mean(anxiety, na.rm = TRUE)
  )
```

```
## # A tibble: 4 x 5
##   occupation_group      n mean_stress mean_depression mean_anxiety
##   <chr>          <int>      <dbl>         <dbl>         <dbl>
## 1 Full-Time      201     -0.0589         -0.0448        -0.0169
## 2 Part-Time       36      0.0756          0.127         0.107
## 3 Student       109      0.0739          0.0126        -0.0677
## 4 Unemployed (and job seeking) 24      0.109          0.561         0.346
```

```
mental_long <- df_job %>%
  pivot_longer(
    cols = c(stress, depression, anxiety),
    names_to = "outcome",
    values_to = "score"
  )

ggplot(mental_long, aes(x = occupation_group, y = score, fill = occupation_group)) +
  geom_boxplot() +
  facet_wrap(~ outcome, scales = "free_y") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  labs(
    title = "Stres, depresija i anksioznost po zanimanju",
    x = "Zanimanje",
    y = "Rezultat"
  )
```

Stres, depresija i anksioznost po zanimanju



Vizualni pregled distribucija pokazuje da se razine stresa, depresije i anksioznosti uvelike preklapaju između skupina definiranih prema radnom statusu (zanimanju), što upućuje na izražene individualne razlike unutar skupina. Iako nezaposleni sudionici pokazuju viši medijan depresivnosti u odnosu na ostale skupine, razlike nisu statistički potvrđene. Također je vidljivo da se veći broj ekstremnih vrijednosti javlja u skupini zaposlenih na puno radno vrijeme, što dodatno ukazuje na veliku heterogenost unutar te skupine. Razine stresa pokazuju vrlo slične obrasce u svim skupinama, dok se anksioznost ne pojavljuje sustavno povezanom sa zanimanjem. Ovi nalazi sugeriraju da radni status sam po sebi ima ograničen doprinos objašnjenju mentalnog zdravlja te da individualne crte ličnosti vjerojatno imaju snažniju ulogu.

Provođenje ANOVA analize - Razlikuju li se razine anksioznosti, depresije i stresa po zanimanju (radnim statusima)?

Za početak je provedena provjera pretpostavki normalnosti distribucije i homogenosti varijanci za varijable anksioznost, depresiju i stres. U nastavku su prikazani rezultati testova.

Test pretpostavke normalnosti za anksioznost

```
require(nortest)

# Lilliefors test normalnosti (ukupno)
lillie.test(df_job$anxiety)
```

```
##
```

```
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$anxiety
## D = 0.039549, p-value = 0.1715
```

```
# Lilliefors test po skupinama zanimanja
lillie.test(df_job$anxiety[df_job$occupation_group == "Full-Time"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$anxiety[df_job$occupation_group == "Full-Time"]
## D = 0.061511, p-value = 0.06185
```

```
lillie.test(df_job$anxiety[df_job$occupation_group == "Part-Time"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$anxiety[df_job$occupation_group == "Part-Time"]
## D = 0.15146, p-value = 0.03593
```

```
lillie.test(df_job$anxiety[df_job$occupation_group == "Unemployed (and job seeking)"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$anxiety[df_job$occupation_group == "Unemployed (and job seeking)"]
## D = 0.11293, p-value = 0.5953
```

```
lillie.test(df_job$anxiety[df_job$occupation_group == "Student"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$anxiety[df_job$occupation_group == "Student"]
## D = 0.042081, p-value = 0.9066
```

```
par(mfrow = c(1, 2), mar = c(4, 3, 2, 1))


hist(
  df_job$anxiety[df_job$occupation_group == "Full-Time"],
  main = "Anxiety - Full-Time",
  xlab = "Anxiety",
  col = "lightgray",
  border = "white"
)

hist(
  df_job$anxiety[df_job$occupation_group == "Student"],
```

```

main = "Anxiety - Student",
xlab = "Anxiety",
col = "lightgray",
border = "white"
)

```



```

par(mfrow = c(1, 1))

```

Iz dobivenih ispisa zaključujemo da na razini značajnosti $\alpha = 0.05$ nema potrebe za odbacivanjem nulte hipoteze o normalnosti distribucije anksioznosti na razini cijelog uzorka ($p > 0.05$). Na temelju grafičke analize histograma može se zaključiti da distribucije anksioznosti za skupine zaposlenih na puno radno vrijeme i studenata približno slijede normalnu distribuciju. Uočena manja odstupanja od savršene simetrije nisu izražena te se ne smatraju statistički relevantnima.

Iako su testovi normalnosti i grafičke provjere provedeni za sve skupine, ovdje su prikazani samo rezultati za skupine zaposlenih na puno radno vrijeme i studenata radi vizualne reprezentacije. Postoje manja odstupanja od normalnosti u skupini Part-Time, ali to je opravdano manjim brojem članova te skupine.

Test pretpostavke normalnosti za depresiju

```

require(nortest)

# Lilliefors test normalnosti (ukupno)
lillie.test(df_job$depression)

```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$depression
## D = 0.089732, p-value = 1.443e-07
```

```
# Lilliefors test po skupinama zanimanja
lillie.test(df_job$depression[df_job$occupation_group == "Full-Time"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$depression[df_job$occupation_group == "Full-Time"]
## D = 0.10029, p-value = 4.153e-05
```

```
lillie.test(df_job$depression[df_job$occupation_group == "Part-Time"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$depression[df_job$occupation_group == "Part-Time"]
## D = 0.16237, p-value = 0.01736
```

```
lillie.test(df_job$depression[df_job$occupation_group == "Unemployed (and job seeking)"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$depression[df_job$occupation_group == "Unemployed (and job seeking)"]
## D = 0.11286, p-value = 0.5964
```

```
lillie.test(df_job$depression[df_job$occupation_group == "Student"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$depression[df_job$occupation_group == "Student"]
## D = 0.085623, p-value = 0.0476
```

Lillieforsov test normalnosti ukazuje na statistički značajno odstupanje distribucije depresije od normalnosti na razini cijelog uzorka, kao i unutar svih skupina osim kod nezaposlenih ($p < 0.05$). Kod studentske skupine odstupanje je granično.

Unatoč utvrđenim odstupanjima od normalnosti, primjena parametarskih metoda smatra se opravdanom s obzirom na veličinu uzoraka te poznatu robusnost linearne regresije i ANOVA-e na umjerena kršenja pretpostavke normalnosti.

Test pretpostavki normalnosti za stres

```

require(nortest)

# Lilliefors test normalnosti (ukupno)
lillie.test(df_job$stress)

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$stress
## D = 0.035177, p-value = 0.3226

# Lilliefors test po skupinama zanimanja
lillie.test(df_job$stress[df_job$occupation_group == "Full-Time"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$stress[df_job$occupation_group == "Full-Time"]
## D = 0.054948, p-value = 0.1461

lillie.test(df_job$stress[df_job$occupation_group == "Part-Time"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$stress[df_job$occupation_group == "Part-Time"]
## D = 0.091433, p-value = 0.6263

lillie.test(df_job$stress[df_job$occupation_group == "Unemployed (and job seeking)"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$stress[df_job$occupation_group == "Unemployed (and job seeking)"]
## D = 0.070023, p-value = 0.9916

lillie.test(df_job$stress[df_job$occupation_group == "Student"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: df_job$stress[df_job$occupation_group == "Student"]
## D = 0.062087, p-value = 0.3808

```

Test normalnosti proveden je za varijablu stresa na razini cijelog uzorka, kao i unutar skupina prema radnom statusu. Rezultati Lillieforsovog testa pokazuju da nijedan od provedenih testova nije statistički značajan ($p > 0.05$), kako na ukupnoj razini, tako i unutar promatranih skupina - ne možemo odbaciti nultu hipotezu o normalnosti uzorka.

Test pretpostavki homogenosti varijanci za anksioznost

```
bartlett.test(df_job$anxiety ~ df_job$occupation_group)

##
## Bartlett test of homogeneity of variances
##
## data: df_job$anxiety by df_job$occupation_group
## Bartlett's K-squared = 1.1147, df = 3, p-value = 0.7735

var((df_job$anxiety[df_job$occupation_group=='Full-Time']))

## [1] 0.9467874

var((df_job$anxiety[df_job$occupation_group=='Part-Time']))

## [1] 1.159903

var((df_job$anxiety[df_job$occupation_group=='Unemployed (and job seeking)']))

## [1] 1.070241

var((df_job$anxiety[df_job$occupation_group=='Student']))

## [1] 1.091825
```

Bartlettov test pokazao je da su varijance anksioznosti između skupina zanimanja međusobno jednake ($p = 0.774$). I pojedinačne varijance po skupinama su vrlo slične, bez izraženih odstupanja. Time je zadovoljena pretpostavka homogenosti varijanci, što opravdava primjenu ANOVA testa za usporedbu anksioznosti između skupina.

Test pretpostavki homogenosti varijanci za depresiju

```
bartlett.test(df_job$depression ~ df_job$occupation_group)

##
## Bartlett test of homogeneity of variances
##
## data: df_job$depression by df_job$occupation_group
## Bartlett's K-squared = 0.82771, df = 3, p-value = 0.8428

var((df_job$depression[df_job$occupation_group=='Full-Time']))

## [1] 1.223933
```

```
var((df_job$depression[df_job$occupation_group=='Part-Time']))
```

```
## [1] 1.220683
```

```
var((df_job$depression[df_job$occupation_group=='Unemployed (and job seeking)']))
```

```
## [1] 0.9148913
```

```
var((df_job$depression[df_job$occupation_group=='Student']))
```

```
## [1] 1.222059
```

Bartlettov test homogenosti varijanci za depresiju pokazao se neznačajnim. Dodatno, izračunate varijance po skupinama su vrlo slične. Ovi podaci upućuju na to da je pretpostavka homogenosti varijanci zadovoljena.

Test pretpostavki homogenosti varijanci za stres

```
bartlett.test(df_job$stress ~ df_job$occupation_group)
```

```
##
```

```
## Bartlett test of homogeneity of variances
```

```
##
```

```
## data: df_job$stress by df_job$occupation_group
```

```
## Bartlett's K-squared = 3.2863, df = 3, p-value = 0.3495
```

```
var((df_job$stress[df_job$occupation_group=='Full-Time']))
```

```
## [1] 1.159828
```

```
var((df_job$stress[df_job$occupation_group=='Part-Time']))
```

```
## [1] 0.8855903
```

```
var((df_job$stress[df_job$occupation_group=='Unemployed (and job seeking)']))
```

```
## [1] 1.022324
```

```
var((df_job$stress[df_job$occupation_group=='Student']))
```

```
## [1] 1.408198
```

Kao i u prethodnim, testovima homogenosti varijanci, test za stres nije pokazao statistički značajne razlike među skupinama zanimanja (radnog statusa), iako je uočljiva nešto veća varijabilnost u skupini studenata. Unatoč razlikama (koje nisu dovoljno izražene), potvrđena je homogenost varijanci za varijablu stres.


```
summary(aov(anxiety ~ occupation_group, data = df_job))
```

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## occupation_group  3    3.8   1.281   1.258  0.288
## Residuals       366  372.5   1.018
```

```
summary(aov(depression ~ occupation_group, data = df_job))
```

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## occupation_group  3    8.3   2.756   2.29  0.078 .
## Residuals       366  440.5   1.204
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(aov(stress ~ occupation_group, data = df_job))
```

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## occupation_group  3    1.8   0.5917   0.494  0.687
## Residuals       366  438.6   1.1983
```

Provedene su jednosmjerne analize varijance (ANOVA) s ciljem ispitivanja razlika u razini anksioznosti, depresije i stresa između skupina definiranih prema radnom statusu (`occupation_group`). Prije provođenja ANOVA-e ispitane su pretpostavke normalnosti distribucije i homogenosti varijanci za sve promatrane varijable. Iako su kod pojedinih varijabli uočena manja odstupanja od normalnosti, s obzirom na veličinu uzorka i robusnost ANOVA-e na umjerena kršenja ove pretpostavke, primjena parametarskih metoda smatrana je opravdanom.

Rezultati jednosmjerne ANOVA-e nisu pokazali statistički značajne razlike u razini anksioznosti između skupina radnog statusa, $F(3, 366) = 1.258$, $p = 0.288$. Također, nisu utvrđene statistički značajne razlike u razini stresa, $F(3, 366) = 0.4944$, $p = 0.687$.

Za razinu depresije uočen je trend prema razlikama između skupina, no rezultat nije dosegao konvencionalnu razinu statističke značajnosti, $F(3, 366) = 2.29$, $p = 0.078$. Dobiveni nalazi upućuju na to da radni status sam po sebi nije snažan prediktor razine mentalnog zdravlja u promatranom uzorku.

Višestruka linearna regresija: doprinos radnog statusa anksioznosti uz kontrolu crta ličnosti

```
model_anxiety <- lm(
  anxiety ~ occupation_group +
  narcissism + machiavelism + psychoticism + sadism + neuroticism +
  extraversion + openness + agreeableness + conscientiousness,
  data = df_job
)

summary(model_anxiety)
```

```
##
## Call:
```

```

## lm(formula = anxiety ~ occupation_group + narcissism + machiavelism +
##      psychoticism + sadism + neuroticism + extraversion + openness +
##      agreeableness + conscientiousness, data = df_job)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.8996 -0.4889  0.0388  0.5458  3.2993
##
## Coefficients:
##              Estimate Std. Error t value
## (Intercept)      0.02965    0.06545   0.453
## occupation_groupPart-Time      0.15199    0.16864   0.901
## occupation_groupStudent     -0.12761    0.11065  -1.153
## occupation_groupUnemployed (and job seeking)  0.03057    0.21044   0.145
## narcissism      -0.05830    0.06341  -0.919
## machiavelism     0.09415    0.05824   1.617
## psychoticism     0.07842    0.06832   1.148
## sadism           0.06215    0.06370   0.976
## neuroticism      0.36507    0.06493   5.622
## extraversion     0.10847    0.06926   1.566
## openness         0.06268    0.05057   1.240
## agreeableness    -0.03295    0.06455  -0.510
## conscientiousness -0.01173    0.06490  -0.181
##              Pr(>|t|)
## (Intercept)      0.651
## occupation_groupPart-Time      0.368
## occupation_groupStudent      0.250
## occupation_groupUnemployed (and job seeking)  0.885
## narcissism       0.358
## machiavelism     0.107
## psychoticism     0.252
## sadism           0.330
## neuroticism      3.8e-08 ***
## extraversion     0.118
## openness         0.216
## agreeableness    0.610
## conscientiousness 0.857
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9141 on 357 degrees of freedom
## Multiple R-squared:  0.2074, Adjusted R-squared:  0.1808
## F-statistic: 7.785 on 12 and 357 DF,  p-value: 6.727e-13

```

U svrhu ispitivanja odnosa između radnog statusa i anksioznosti proveden je model višestruke linearne regresije kojim se ispituje doprinos radnog statusa povrh crta ličnosti.

Rezultati pokazuju da je regresijski model statistički značajan u cjelini, $F(12, 357) = 7.79$, $p = 6.73 \times 10^{-13}$. Model objašnjava oko 21% varijance anksioznosti ($R\text{-squared} = 0.2074$), dok prilagođeni koeficijent determinacije iznosi 0.1808. Iako je objašnjeni udio varijance manji u usporedbi s modelima za stres i depresiju, dobivene vrijednosti upućuju na to da model ima smisla za interpretaciju.

Analizom mračnih crta ličnosti nije utvrđen nijedan statistički značajan jedinstveni prediktor anksioznosti. Narcizam, makijavelizam, psihoticizam i sadizam nisu pokazali značajan doprinos nakon kontrole ostalih crta ličnosti, što sugerira da se njihova povezanost s anksioznošću ne zadržava u ovom multivarijantnom modelu.

Unutar petofaktorskog modela ličnosti, neuroticizam se jasno istaknuo kao ključni prediktor anksioznosti ($\beta = 0.37$, $p < 0.001$). Osobe s višim razinama neuroticizma pokazuju izraženiju anksioznost, neovisno o radnom statusu i ostalim osobinama ličnosti, što je u skladu s postojećim teorijskim i empirijskim nalazima. Ekstraverzija nije bila statistički značajan prediktor anksioznosti ($p = 0.118$), kao ni ostale Big Five crte ličnosti.

Višestruka linearna regresija: doprinos radnog statusa depresiji uz kontrolu crta ličnosti

```
model_depression <- lm(
  depression ~ occupation_group +
  narcissism + machiavelism + psychoticism + sadism + neuroticism +
  extraversion + openness + agreeableness + conscientiousness,
  data = df_job
)

summary(model_depression)
```

```
##
## Call:
## lm(formula = depression ~ occupation_group + narcissism + machiavelism +
##      psychoticism + sadism + neuroticism + extraversion + openness +
##      agreeableness + conscientiousness, data = df_job)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.02443 -0.46695  0.04059  0.47651  2.56926
##
## Coefficients:
##              Estimate Std. Error t value
## (Intercept)      0.061512   0.058468    1.052
## occupation_groupPart-Time -0.008989   0.150665   -0.060
## occupation_groupStudent  -0.039037   0.098851   -0.395
## occupation_groupUnemployed (and job seeking) -0.187553   0.188009   -0.998
## narcissism        -0.025449   0.056648   -0.449
## machiavelism       0.087583   0.052027    1.683
## psychoticism       0.133949   0.061037    2.195
## sadism            0.012428   0.056907    0.218
## neuroticism       0.437118   0.058011    7.535
## extraversion     -0.306129   0.061879   -4.947
## openness          0.031523   0.045180    0.698
## agreeableness     0.056224   0.057668    0.975
## conscientiousness -0.020256   0.057979   -0.349
##
##              Pr(>|t|)
## (Intercept)      0.2935
## occupation_groupPart-Time    0.9525
## occupation_groupStudent    0.6931
## occupation_groupUnemployed (and job seeking) 0.3192
## narcissism        0.6535
## machiavelism      0.0932 .
## psychoticism      0.0288 *
## sadism            0.8273
```

```
## neuroticism          4.05e-13 ***
## extraversion         1.16e-06 ***
## openness             0.4858
## agreeableness        0.3302
## conscientiousness     0.7270
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8166 on 357 degrees of freedom
## Multiple R-squared:  0.4695, Adjusted R-squared:  0.4517
## F-statistic: 26.33 on 12 and 357 DF,  p-value: < 2.2e-16
```

Kako bi se ispitao doprinos radnog statusa razini depresije uz kontrolu crta ličnosti, proveden je model višestruke linearne regresije.

Regresijski model pokazao se statistički značajnim u cjelini, $F(12, 357) = 26.33$, $p < 2.2 \times 10^{-16}$. Model objašnjava približno 47% varijance depresije ($R\text{-squared} = 0.4695$), dok prilagođeni koeficijent determinacije iznosi 0.4517, što upućuje na vrlo dobru objašnjavajuću snagu modela.

Među mračnim crtama ličnosti, psihoticizam se pokazao statistički značajnim pozitivnim prediktorom depresije ($\beta = 0.134$, $p = 0.029$), što sugerira da osobe s izraženijim obilježjima psihoticizma imaju višu razinu depresije i nakon kontrole ostalih osobina ličnosti i radnog statusa. Makijavelizam je pokazao slab, ali statistički neznačajan trend ($\beta = 0.088$, $p = 0.093$), dok narcizam i sadizam nisu imali značajan doprinos u objašnjenju depresije.

Unutar petofaktorskog modela ličnosti, neuroticizam se ponovno istaknuo kao najsnažniji pozitivni prediktor depresije ($\beta = 0.437$, $p < 0.001$), potvrđujući njegovu ključnu ulogu u objašnjenju emocionalnih poteškoća. Za razliku od modela za anksioznost i stres, ekstraverzija se ovdje pokazala statistički značajnim negativnim prediktorom depresije ($\beta = -0.306$, $p < 0.001$), što upućuje na niže razine depresije kod osoba s višom razinom ekstraverzije. Ostale crte Big Five modela nisu se pokazale statistički značajnima.

Višestruka linearna regresija: doprinos radnog statusa stresu uz kontrolu crta ličnosti

```
model_stress <- lm(
  stress ~ occupation_group +
  narcissism + machiavelism + psychoticism + sadism + neuroticism +
  extraversion + openness + agreeableness + conscientiousness,
  data = df_job
)

summary(model_stress)

##
## Call:
## lm(formula = stress ~ occupation_group + narcissism + machiavelism +
##      psychoticism + sadism + neuroticism + extraversion + openness +
##      agreeableness + conscientiousness, data = df_job)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.0923 -0.5034  0.0875  0.5923  3.2132
##
```

```

## Coefficients:
##
##              Estimate Std. Error t value
## (Intercept)      0.0258670   0.0661666    0.391
## occupation_groupPart-Time      0.0674423   0.1705019    0.396
## occupation_groupStudent      0.0296155   0.1118665    0.265
## occupation_groupUnemployed (and job seeking) -0.3841763   0.2127636   -1.806
## narcissism      -0.0019928   0.0641068   -0.031
## machiavelism      0.1107641   0.0588771    1.881
## psychoticism      0.2158670   0.0690734    3.125
## sadism      -0.0355856   0.0643995   -0.553
## neuroticism      0.3993105   0.0656486    6.083
## extraversion     -0.0960818   0.0700258   -1.372
## openness      0.1384934   0.0511283    2.709
## agreeableness     -0.0468288   0.0652604   -0.718
## conscientiousness -0.0002919   0.0656131   -0.004
##
##              Pr(>|t|)
## (Intercept)      0.69608
## occupation_groupPart-Time      0.69267
## occupation_groupStudent      0.79136
## occupation_groupUnemployed (and job seeking) 0.07182 .
## narcissism      0.97522
## machiavelism      0.06075 .
## psychoticism      0.00192 **
## sadism      0.58090
## neuroticism      3.05e-09 ***
## extraversion      0.17090
## openness      0.00708 **
## agreeableness      0.47349
## conscientiousness 0.99645
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9241 on 357 degrees of freedom
## Multiple R-squared:  0.3076, Adjusted R-squared:  0.2843
## F-statistic: 13.22 on 12 and 357 DF,  p-value: < 2.2e-16

```

Iz modela višestruke linearne regresije koji izračunava doprinos zanimanja stresu povrh ličnosti zaključujemo sljedeće stvari.

Model se pokazuje statistički značajnim u cjelini s vrijednostima $F(12, 357) = 13.22$ i $p = 2.2 \times 10^{-16}$ (< 0.001) te je Multiple R-squared = 0.3076 i Adjusted R-squared = 0.2843. Ove vrijednosti upućuju da model ima dobru objašnjavajuću snagu.

Među mračnim crtama ličnosti, psihoticizam se istaknuo kao statistički značajan pozitivan prediktor ($\beta = 0.2158670$, $p = 0.00192$ (< 0.01)). To znači da osobe s višim razinama psihoticizma pokazuju višu razinu stresa, čak i nakon utjecaja ostalih crta ličnosti i oblika radnog angažmana. Makijavelizam je pokazao trend prema pozitivnoj povezanosti ($\beta = 0.1107641$, $p = 0.06075$ (< 0.1)), ali rezultati su nedovoljni za snažnu povezanost. Narcizam i sadizam nisu pokazali značajan doprinos.

Unutar petofaktorskog Big 5 modela, neuroticizam se pokazao daleko najsnažnijim prediktorom ishoda ($\beta = 0.3993105$, $p = 3.05 \times 10^{-9}$ (< 0.001)). Viša razina neurocitizma povezana je s višom razinom stresa, neovisno o radnom odnosu i ostalim crtama ličnosti. Ovaj rezultat je u potpunosti u skladu s teorijskim očekivanjima. Izdvajamo i otvorenost kao statistički značajan pozitivvan prediktor ($\beta = 0.1384934$, $p = 0.00708$ (< 0.01)). Ovaj podatak sugerira da osobe s više otvorenosti mogu biti osjetljivije na stres. Ekstraverzija, ugodnost i savjesnost nisu pokazale statistički značajan utjecaj u ovom modelu.